

Modelovanje Gitarskih Pojačala i Efekata

Ilija Kalinić
E9 7/2023
kalinic.e97.2023@uns.ac.rs
ilija.kalinic@gmail.com

I. UVOD

Modelovanje analognih gitarskih pojačala i efekata neuronskim mrežama je aktuelna tema jer omogućava da se zvuk skupe ili retke opreme reprodukuje softverski, u digitalnim radnim stanicama (Digital Audio Workstation – DAW) i embedded uređajima. Problem se može posmatrati kao identifikacija nelinearnog sistema: na osnovu uparenih snimaka ulaza i izlaza ciljnog uređaja uči se preslikavanje koje reprodukuje njegovo ponašanje, bez poznavanja unutrašnje šeme (black-box režim modelovanja).

Praktična primena treba da zadovolji dva cilja. Model treba da verodostojno reprodukuje zvuk (kvalitet rekonstrukcije), ali i da obrađuje audio uzorke dovoljno brzo da ispoštuje brzinu rada koju definiše radna frekvencija (sample rate). U ovom projektu, sample rate je 44,1 kHz u svim eksperimentima. Cilj ovog rada je da se na zajedničkom skupu podataka i uz isti eksperimentalnu metodologiju uporede tri arhitekture po obe ose: koliko dobro rekonstruišu signal i kolika im je računska cena.

II. PREGLED LITERATURE

Damskägg i saradnici [1] su među prvima primenili duboke neuronske mreže na modelovanje audio distorzija u realnom vremenu, koristeći varijantu WaveNet arhitekture na snimcima pojačala i distorzija pedala. Wright i saradnici [2] su razvili modele gitarskih pojačala zasnovane na rekurentnim mrežama (LSTM) i pokazali da relativno mali rekurentni modeli mogu verno da oponašaju nelinearno ponašanje pojačala uz nisku latenciju. Steinmetz i Reiss [3] su u biblioteci auraloss definisali skup loss funkcija prilagođenih audio signalima, uključujući error-to-signal ratio (ESR) i multi-resolution STFT loss, koje su relevantne za izbor audio metrika u ovom radu. Projekat koristi sopstvene implementacije opisanih recepata.

Izbor veličine referentnog modela prati projekat GuitarML Proteus [4], koji za modelovanje pojačala koristi LSTM sa 40 skrivenih jedinica. Proteus se ovde navodi isključivo kao obrazloženje izbora veličine LSTM modela, dok su implementacija, eksperimenti i trenirani modeli razvijeni u ovom projektu na ručno kreiranom skupu podataka.


Poređenje sa sličnim rešenjima je metodološko: Damskägg i saradnici [1] koriste WaveNet pristup za distorzije, Wright i saradnici [2] ispituju kompaktne rekurentne modele pojačala, dok Proteus [4] daje praktičan primer veličine LSTM-40. Ovaj rad poredi tri arhitekture na četiri ciljna lanca uređaja na isti način. Skupovi podataka, hardver i postupci merenja razlikuju se od prethodnih radova, pa se njihove brojčane metrike ne porede direktno.

III. SKUP PODATAKA

Korišćen je ručno pravljen skup podataka trajanja 14,76 minuta na 44,1 kHz, sačuvan u mono FP32 WAV formatu. Ulazni signal (DI.wav) nastao je nadovezivanjem više izvođenja na gitari i bas gitari. Svaki ciljni signal snimljen je u jednom neprekidnom prolazu reprodukcije istog ulaznog signala kroz ciljni uređaj, pa su svi parovi vremenski poravnati na istom materijalu.

Snimanje, montaža i izvoz urađeni su u programu REAPER uz snimanje i izvoz u 32-bitnom floating-point WAV formatu. Lanac reprodukcije bio je: REAPER, izlaz 1 audio interfejsa Focusrite Scarlett 2i4, ciljni uređaj, ulaz 1 istog interfejsa. Uređaji od čije kombinacije je napravljen skup podataka su bili Boss DS-1, Ibanez Tube Screamer Mini, Pearl PFT-101 Duo Reverb, i mikrofoni Shure SM57. Pedale Boss DS-1 i Ibanez TS Mini snimane su direktno na ulaz interfejsa. “Pearl clean” i “Full rig” (DS1 -> Pearl) snimani su mikrofonom SM57. Kod pedala pomeran je samo potencijometar za “gain”, čiji procenat je u nazivu snimka (75 %), dok su ostali parametri bili fiksni. Pojačalo Pearl PFT-101 snimljeno je mikrofonom Shure SM57 postavljenim oko jednog inča od rešetke, aksijalno, ka granici između centralnog poklopca i konusa zvučnika.

Poravnanje ulaza i cilja određeno je eksperimentalno: zajednički pomak od -41 sample-a izabran je jer je davao najbolji ESR na validacionom segmentu za sve snimke i bio fizikalno verodostojan za gotovo identičan analogni lanac i isti digitalni interfejs. Nakon poravnanja, raspoloživih 39,051 miliona semplova podeljeno je u kontinuirane trening (31,162 miliona), validacione (3,89 miliona) i test (3,90 miliona) regione, razdvojene sa dve praznine od po 44100 smplova (jedna sekunda). Kontinuirana podela sa prazninama zamenila je prvobitno predloženu nasumičnu podelu kako bi se smanjilo curenje informacija između susednih smplova. Normalizacija je isključena kako bi se očuvao snimljeni odnos pojačanja između ulaza i cilja.



Slika 1 Tok snimanja i kontinuirana podela skupa podataka sa zaštitnim prazninama.

IV. METODOLOGIJA

A. Arhitekture modela

Upoređene su tri arhitekture, sve sa skalarnim ulazom i skalarnim izlazom. Referentni model je jednoslojni LSTM sa 40 skrivenih jedinica, linearnom izlaznom projekcijom i skip vezom sa ulaza na izlaz, sa 6921 parametar. LSTM konfiguracija je napravljena po uzoru na rešenje iz projekta [GuitarML](#). Prva alternativa je jednoslojni GRU sa 46 skrivenih jedinica iste ulazno-izlazne strukture, sa 6809 parametara (oko 1,6 % manje od referentnog), izabran da bude približno uporediv po kapacitetu. Druga alternativa je WaveNet (kauzalna dilatirana konvolutivna mreža, tri grupe od po 11

dilatiranih rezidualnih blokova, ukupno 33 bloka, uz ulaznu i izlaznu projekciju) sa 12.129 parametara (oko 75 % više od referentnog), kao veća konvolutivna alternativa. Broj parametara i konfiguracija blokova za WaveNet model je napravljena po uzoru na rešenje iz projekta [Neural Amp Modeler](#). Poređenje dakle nije poređenje jednakih kapaciteta, što se uzima kao ograničenje.

Ciljni uređaj	LSTM-40 (referentni)	GRU-46	WaveNet-12k
Boss DS-1	6921	6809	12129
TS Mini	6921	6809	12129
Pearl (clean)	6921	6809	12129
Puni rig	6921	6809	12129

Tabela 1. Broj parametara modela za svaki ciljni uređaj.

B. Treniranje

Svi modeli trenirani su na isti način: Adam optimizator (learning rate 0,004, eksponencijalno opadanje sa faktorom 0,994), 100 epoha, seed 42, deterministički režim na NVIDIA RTX 3050. Loss funkcija bila je **MSE + 0,0005 · multi-resolution STFT loss**, po uzoru na NAM, a za izbor najboljeg checkpoint-a korišćena je odvojena validaciona metrika ESR (Error to Signal Ratio) bez pre-emphasis filtera (po uzoru na NAM).

C. Metrike

Kvalitet rekonstrukcije meren je: (1) srednjom kvadratnom greškom (MSE); (2) error-to-signal ratio (ESR), odnosno odnosom energije greške i energije ciljnog signala, gde je manja vrednost bolja, a ESR = 1 znači da je energija greške jednaka energiji cilja; (3) multi-resolution STFT distance (MR-STFT); i (4) korelacijom između predikcije i cilja. ESR, MSE i korelacija računaju se nad celim evaluacionim segmentom nakon početnih 4 096 sample-a za stabilizaciju stanja. MR-STFT koristi do deset fiksnih, nepreklopajućih prozora od tri sekunde. Treniranje koristi NAM STFT konfiguraciju za metriku, a evaluacija i monitoring koriste konfiguraciju sa FFT veličinama 512, 1024 i 2048, koracima 128, 256 i 512 i prozorima 512, 1024 i 2048 odbiraka. Za fiksni netih cilj, MSE i ESR su srazmerni, pa njihova saglasnost nije nezavisni dokaz perceptualnog kvaliteta.

Tokom eksperimenata je otkriveno da ukoliko merenje MR-STFT obuhvata segmente koji predstavljaju digitalnu tišinu (vrednosti sa nulama) metrika naglo raste. Dodat je nov režim računanja relativnih metrika. ESR i MS-STFT ne računaju segmente digitalne tišine, dok se apsolutne dijagnostike (MSE, RMS) ih uzimaju u račun.


V. REZULTATI

A. Kvalitet rekonstrukcije

Tabela II prikazuje rezultate kvaliteta na test segmentu za sva četiri uređaja, u apsolutnim vrednostima i u odnosu na referentni LSTM-40 (odnos kandidata i reference; za metrike gde je manje bolje, negativna promena je poboljšanje). WaveNet je postigao najbolji (najniži) ESR na svakom uređaju, GRU je bio drugi, a referentni LSTM treći. Najveća prednost WaveNet-a je na punom lancu ("Full rig" ESR 0,0161, za 94,7 % manji od ESR-a LSTM-a), a najmanja na DS-1 (ESR manji za 47,9 %).

Uređaj / model	ESR	ESR u poređenju sa ref. modelom	MSE	MR-STFT	MR-STFT (ref.)	korelacija
Boss DS-1, WaveNet-12k	0.0026	0.52x (-47.9%)	4.98e-05	0.439	0.77x (-23.2%)	0.9988
Boss DS-1, GRU-46	0.0034	0.70x (-30.5%)	6.64e-05	0.579	1.01x (+1.3%)	0.9983
Boss DS-1, LSTM-40 (ref.)	0.0049	1.00x (0.0%)	9.54e-05	0.572	1.00x (0.0%)	0.9977
TS Mini, WaveNet-12k	0.0003	0.30x (-69.9%)	3.58e-06	0.546	0.83x (-16.9%)	0.9999
TS Mini, GRU-46	0.0006	0.60x (-40.0%)	7.16e-06	0.616	0.94x (-6.2%)	0.9997
TS Mini, LSTM-40 (ref.)	0.0010	1.00x (0.0%)	1.19e-05	0.657	1.00x (0.0%)	0.9995
Pearl (clean), WaveNet-12k	0.0197	0.41x (-59.3%)	1.54e-04	1.573	0.93x (-7.1%)	0.9904
Pearl (clean), GRU-46	0.0415	0.86x (-14.4%)	3.25e-04	1.831	1.08x (+8.1%)	0.9791
Pearl (clean), LSTM-40 (ref.)	0.0484	1.00x (0.0%)	3.79e-04	1.694	1.00x (0.0%)	0.9761
Puni rig, WaveNet-12k	0.0161	0.05x (-94.7%)	1.06e-04	0.715	0.45x (-54.8%)	0.9920
Puni rig, GRU-46	0.2924	0.95x (-4.7%)	1.92e-03	1.425	0.90x (-9.8%)	0.8427
Puni rig, LSTM-40 (ref.)	0.3067	1.00x (0.0%)	2.01e-03	1.579	1.00x (0.0%)	0.8346

Tabela 2. Kvalitet rekonstrukcije na test segmentu, u apsolutnim vrednostima i u odnosu na LSTM-40.



Slika 2. Primer ciljnog signala i predikcije referentnog LSTM-40 modela na isečku od 20 ms iz DS-1 test segmenta, sa ostatkom (greškom).

B. Cena izvođenja na procesoru

Merenja su izvršena na procesoru 13. generacije Intel Core i5-13400F (Linux 6.8, PyTorch 2.11.0, jedan thread, float32, eager mod izvršavanja), sa 3 zagrevanja i 20 merenja, po jedan model u procesu. Tabela III prikazuje offline real-time factor (RTF) i p95 vreme obrade blokova od 128 sempla u odnosu na deadline od 2,9025 ms. RTF manji od 1 znači da model obrađuje audio brže nego što stiže.

Cilj / model	offline RTF	p95 (128) [ms]	deadline (128) [ms]	promasaji (128)
Boss DS-1, L S T M - 4 0 (ref.)	0.0431	0.144	2.902	0/20
Boss DS-1, GRU-46	0.3470	1.158	2.902	0/20
Boss DS-1, WaveNet-12k	0.3798	3.481	2.902	20/20
TS Mini, L S T M - 4 0 (ref.)	0.0400	0.163	2.902	0/20
TS Mini, GRU-46	0.3606	1.154	2.902	0/20
TS Mini, WaveNet-12k	0.3252	3.365	2.902	20/20
Pearl (clean), L S T M - 4 0 (ref.)	0.0396	0.146	2.902	0/20
Pearl (clean), GRU-46	0.3471	1.091	2.902	0/20
Pearl (clean), WaveNet-12k	0.2727	2.919	2.902	6/20
Full rig, L S T M - 4 0 (ref.)	0.0431	0.162	2.902	0/20
Full rig, GRU-46	0.3627	1.168	2.902	0/20
Full rig, WaveNet-12k	0.3632	3.439	2.902	20/20

Tabela 3. Offline RTF i p95 vreme obrade blokova od 128 sempla u odnosu na deadline.

Sva tri modela imaju offline RTF manji od 1, pa bi se po tom kriterijumu svi činili dovoljno brzim. Merenje po blokovima, međutim, otkriva bitnu razliku: LSTM-40 i GRU-46 ispunjavaju deadline za sve veličine blokova (0 promasaja u 20 merenja), dok WaveNet za blokove od 64 i 128 sempla premašuje deadline (20/20 promasaja na DS-1, TS Mini i punom rigu; 6/20 na Pearl uz 128 sempla). Slika 3 ilustruje ovo za blok od 128 sempla. Zaključak je da offline RTF sam po sebi nije dovoljan pokazatelj sposobnosti rada u realnom vremenu.


C. Ispravka merenja na tihim segmentima

Pre uvođenja novog režima merenja relativnih metrika gde se ne računaju segmenti digitalne tišine, evaluacija WaveNet modela za DS-1 javljala je srednju MR-STFT vrednost od preko 53 miliona, jer je poslednji fiksni prozor bio digitalna tišina. Nakon ispravke taj prozor se izuzima iz proseka (9 bodovanih i 1 izuzet za DS-1, TS Mini i "Full rig"; 10/0 za Pearl), pa je ispravljena MR-STFT za DS-1 WaveNet 0,439. Ovo pokazuje koliko način agregacije metrika utiče na tumačenje rezultata.

VI. DISKUSIJA


WaveNet daje najniži ESR na svim ciljevima, uz više parametara i premašuje deadline-ova za blokove od 64 i 128 sample-a. GRU-46 je između LSTM-a i WaveNet-a po ESR-u, ali ima viši MR-STFT od LSTM-a na DS-1 i Pearl ciljevima. LSTM-40 i GRU-46 ispunjavaju sve izmerene rokove, a LSTM-40 ima najnižu računsku cenu. Offline RTF WaveNet-a nije uvek najveći, na TS Mini i Pearl ciljevima je niži od GRU.

"Full rig" lanac je posebno težak za rekurentne modele: ESR iznosi 0,307 za LSTM i 0,292 za GRU. WaveNet na tom cilju postiže ESR 0,0161; za njega je Pearl teži cilj po ESR-u (0,0197) i MR-STFT-u. Neformalno slušanje rekonstrukcije TS Mini i DS-1 zvuče uverljivo, dok se kod "Full rig" cilja



čuju primetnije razlike. Neformalno slušanje nije kontrolisana slušna studija i ne dokazuje perceptualnu prednost.

Ograničenja: (1) skup čini jedna nekoliko ručno pravljenih izvođenja, a ne nezavisne sesije, (2) korišćen je jedan seed (42), pa rezultati važe za ova pokretanja, a ne kao statistički dokaz superiornosti; (3) parametri uređaja su fiksni; (4) poređenje nije jednakih kapaciteta (WaveNet ima 75 % više parametara); (5) PyTorch eager mod je korišten za merenje RTF-a i brzinu po blokovima sample-a. U realnoj upotrebi bi bolje performanse dali optimizovani framework-ovi za inference, kao što su ONNX Runtime, RT Neural, ili drugi C++ framework-ovi.



Slika 4. Trade-off kvaliteta i cene: ESR u odnosu na offline RTF za sva četiri cilja i sve tri arhitekture (log-log).

VII. ZAKLJUČAK

Rad je na zajedničkom skupu podataka i uz istu konfiguraciju za trening uporedio LSTM, GRU i WaveNet arhitekture za modelovanje četiri gitarska uređaja. WaveNet je postigao najniži ESR na svim ciljevima. LSTM-40 i GRU-46 ispunili su sve izmerene deadline-ove, a LSTM-40 je imao najnižu računsku cenu. Pokazano je da offline RTF nije dovoljan za zaključak o radu u realnom vremenu, kao i da izbor agregacije spektralnih metrika menja tumačenje rezultata. Budući rad uključuje veći broj seed-ova i uređaja, nezavisne sesije snimanja, poređenje jednakih kapaciteta i upotrebu optimizovanih framework-ova za inference.

VIII. REFERENCE

- [1] [1] E.-P. Damskägg, L. Juvela i V. Välimäki, "Real-Time Modeling of Audio Distortion Circuits with Deep Learning", Proc. Sound and Music Computing Conference (SMC), 2019.
- [2] [2] A. Wright, E.-P. Damskägg, L. Juvela i V. Välimäki, "Real-Time Guitar Amplifier Emulation with Deep Learning", Applied Sciences, vol. 10, br. 3, članak 766, 2020, doi: 10.3390/app10030766.
- [3] [3] C. Steinmetz i J. Reiss, "auraloss: Audio-focused loss functions in PyTorch", Digital Music Research Network (DMRN+15), 2020.
- [4] [4] GuitarML, "Proteus: Guitar amp and pedal modeling", GitHub repozitorijum, <https://github.com/GuitarML/Proteus> (pristupljeno 2026).