

Offline monitoring verzija modela za neural-fx

Ilija Kalinić, E9 7/2023

Predmet: Tehnologije i alati u mašinskom učenju (TiAMU)

MLOps komponenta: monitoring modela

Kontekst i opseg

- Projekat neural-fx (predmet Neuronske mreže): modelovanje gitarskih efekata i pojačala neuronskim mrežama (LSTM, GRU, WaveNet), treniranje, evaluacija, eksportovanje.
- MLOps deo: sloj koji prati ponašanje verzija modela i evaluacionih pokretanja.
- Opseg je offline monitoring nad fiksnim audio suite-om, ne monitoring produkcionog servisa.
 - model je za real-time audio/DSP upotrebu, ne servis koji prima zahteve.
 - fiksni suite provere regresije nije detekcija drifta u produkciji.
- Cilj: pri promeni modela ili konfiguracije proveriti da li nova verzija zadržava prihvatljiv kvalitet, brzinu i stabilnost.

Koncepti monitoringa modela


- Operativne metrike: vreme inference-a, latencija po segmentu, p50 i p95, real-time factor (RTF), veličina artefakta, potrošnja memorije.
- Metrike specifične za MU: ESR, MSE, multi-resolution STFT distance (kvalitet rekonstrukcije audio signala).
- Provere ulaznih podataka i predikcija: učestanost, kanali, dužina, konačnost vrednosti, amplituda, kliping.
- Praćenje karakteristika i predikcija sa predavanja je ovde prilagođeno fiksnom audio suite-u.

Aktuelna praksa i poređenje neural-fx rešenja

- Upravljeni monitoring podržava drift i poređenje skupova, uključujući batch tokove.
- Lokalni audio eksperiment zahteva fiksne regresione primere i audio-specifične provere.
- neural-fx implementira provere, poređenje verzija i odluku; biblioteke obrađuju audio i metrike.
- Izvor: Google Cloud, Vertex AI Model Monitoring capabilities (2024).

Monitoring tok

Prilagođeni offline monitoring tok



- Artefakt (checkpoint ili TorchScript model) i fiksirani audio suite (YAML i heševi).
- Provere ulaznih podataka, inference, metrike, verzionisani izveštaj.
- Poređenje sa deklarisanim pragovima vodi do eksplicitne odluke.

Provere ulaza i predikcije

- Ulaz: sample rate 44,1 kHz, 1 kanal, očekivana dužina segmenta.
- Vrednosti: konačnost (bez NaN i Inf), opseg amplitude, detekcija klipinga.
- Distorzija je ciljni efekat koji se modeluje; numerički kliping je zasebna validaciona briga.
- Predikcija: oblik, konačnost, amplituda, kliping; burn-in i stanje modela.
- Heševi audio fajlova i fingerprint suite-a garantuju da se poredi isti skup.

MSE i ESR: definicije i tumačenje


- MSE je srednja kvadratna greška između predikcije i cilja.
- ESR je odnos energije greške i energije cilja. $ESR = 1$ znači da je greška (šum) jednake energije kao i cilj (manje je bolje).
- Za fiksni netihi cilj, MSE i ESR su srazmerni, pa njihova saglasnost nije dokaz da su signali perceptualno isti.
- Pre-emphasis menja značenje ESR. Ovde se koristi ESR bez pre-emphasis-a.
- Uklanjanje nula. ESR i MR-STFT su nedefinisani na digitalnoj tišini.
- Apsolutne metrike (MSE) računaju nule.

MR-STFT: definicija

- Multi-resolution STFT distance kombinuje spektralnu konvergenciju i log-magnitudu na više rezolucija (FFT 512, 1024, 2048).
- Greška otkrivena u praksi: nasledna spektralna konvergencija deli grešku normom ciljnog spektra uz malu konstantu.
- Na digitalnoj tišini: DS-1 WaveNet je imao srednju MR-STFT preko 53 miliona; ispravljena vrednost je 0,439 (9 bodovanih, 1 izuzet prozor).
- Pouka: agregacija metrika i tretman tišine suštinski menjaju tumačenje.

Operativne metrike: tumačenje

- RTF je odnos vremena inference-a i trajanja zvuka. RTF ispod 1 znači da model obrađuje brže nego što zvuk stiže.
- Offline RTF je protok, ne interaktivna latencija.
- Blok deadline je veličina bloka podeljena sa 44,1 kHz. Promašaj je kada vreme obrade pređe deadline.
- Primer (blok 128, deadline 2,9025 ms): LSTM i GRU 0/20 promašaja; WaveNet 20/20 na tri cilja, iako je njegov offline RTF ispod 1.
- Memorija: RSS (resident set size, pik memorije) je vrhunac celokupnog procesa, ne samo modela.



Uporedivost


- Poređenje je validno samo uz isti fingerprint suite-a, isti recept metrika, istu učestanost i segmente.
- Za latenciju dodatno: isti uređaj, dtype, kategorija inference-a i efektivna veličina chunk-a.
- Checkpoint (stateful chunk-ovi) i TorchScript (cela sekvenca odjednom) ne daju uporedivu latenciju ali se kvalitet se može porediti.
- Nepodudarni ili nevalidni izveštaji vode ka odbijanju poređenja.

Pragovi i odgovor na regresiju

Metrika	Ozbiljnost	Prag
ESR	odbijanje	> 10 %
MR-STFT	odbijanje	> 10 %
MSE	istraga	> 10 %
p95 latencija	istraga	> 20 %
RTF	istraga	> 20 %
vršna memorija (RSS)	istraga	> 20 %
veličina artefakta	istraga	> 10 %

Pragovi se određuju pre pregleda kandidata. Redosled odluke: odbijanje → istraga → prihvatanje; jednakost sa pragom nije prekoračenje.

Kontrolisani rollback: promene metrika



- Baseline: finalni DS-1 LSTM-40 (6 921 parametar).
- Kandidat: DS-1 LSTM-nano (3 129 parametara, starija eksperimentalna konfiguracija).
- Scenarij je kontrolisani rollback (simulacija, ne stvarno raspoređivanje).
- Kandidat je brži (RTF -76 %, p95 -81 %), ali nedopustivo lošiji po kvalitetu.

Kontrolisani rollback: odluka

Metrika	Baseline	Kandidat	Δ %	Prag	Prešao
ESR	1,7499	4,0505	+131,5	10 (odb.)	DA
MR-STFT	5,455	6,275	+15,0	10 (odb.)	DA
MSE	6,0e-6	7,3e-4	+11949	10 (istr.)	DA
p95 [ms]	46,38	8,71	-81,2	20 (istr.)	ne
RTF	0,0329	0,0078	-76,3	20 (istr.)	ne
veličina [B]	96 283	55 400	-42,5	10 (istr.)	ne

Odluka: ODBIJANJE. Zadržati baseline, ispitati razlike, korigovati kandidata i ponoviti isti validacioni skup.

Implementacija i validacioni primeri

- Implementacija: `scripts/monitor.py`, `scripts/compare_monitoring.py` i `neural_fx/monitoring/`.
- Finalni monitoring: 12 izveštaja; 4 test slučaja po 1 s, burn-in 4096, chunk 8192; 52 proverre po izveštaju, sve prošle.
- Rollback: poseban DS-1 validacioni skup. Kandidat prolazi validaciju, ali prelazi pragove kvaliteta.
- Dokaz: `artifacts/gear_comparison_44100/monitoring/tamu/comparison/`.
- NM benchmark: 1 thread, finalni monitoring: 10 thread-ova. Raniji rollback nema zapis broja niti.

Ograničenja, zaključak i reference

- Ovo je offline monitoring fiksnog suite-a, bez vidljivosti produkcionog drifta.
- RSS (resident set size) je vrhunac celog procesa. Veličina checkpoint-a može uključiti stanje treninga.
- Latencija je uporediva samo uz isti runtime identitet, kategoriju i chunk.
- Doprinos: sopstveni tok praćenja, politika praga i dokumentovan odgovor na regresiju, demonstrirano na stvarnoj kontrolisanoj regresiji.
- Reference: Damskägg 2019; Wright 2020; auraloss 2020; PyTorch benchmark docs; PortAudio timing; Google Cloud Model Monitoring.